

MASTER'S THESIS RESEARCH PROPOSAL

CHUM

신뢰 가능한 산업 시계열 이상 탐지를 위한 아키텍처 강건형 제어 이력 유용성 감사

Architecture-Robust Auditing of Control-History Utility
for Reliable Industrial Time-Series Anomaly Detection

검토 대상	추현승 교수	현재 상태	MANUSCRIPT- READY
작성일	2026-08-23	필수 실험	완료 · backlog 없음

결론: 4개 locked event-channel이 TCN·Transformer와 9개 replacement 설정에서 모두 재현됐다. 현재 claim 범위에서 남은 필수 실험은 없다.

LOCKED CELLS	DATASETS	ARCHITECTURES	EVIDENCE QA
4 / 4	2	3	18 / 18

Decision requested · 연구질문 확정 | CHUM을 주 기여로 확정 | 본문 집필 시작

문서 흐름

01 WHY	교수·연구실 최근 경향 → 문제의식 → 연구 공백
02 WHAT	연구질문·가설 → CHUM의 조작적 정의와 기여
03 HOW	Dataset → 전처리 → 모델 → 실험·판정 gate
04 PROOF	TEP → IG → HAI corrected v2 → 최종 민감도
05 DECIDE	의의·한계 → 발전 가능성 → 집필 구조와 결정 요청

이 문서는 결론을 먼저 제시하고, 각 주장에 대응하는 통제와 raw-evidence 판정을 순서대로 연결한다.

0. 교수님께 먼저 보고할 결론

산업 이상 탐지에서 제어 이력은 모든 사건에 보편적으로 유용하지 않다. 그러나 TEP의 특정 **fault-channel** 조합에서는 모델 용량, 비현실적 **masking**, **threshold**, 오경보율, **seed**와 **architecture**를 통제된 뒤에도 추가 탐지 정보가 재현된다. 이 결과는 HAI 21.03의 전역 성능과 일부 직접 공격 **channel**에서도 제한적으로 반복된다.

본 연구의 기여는 새로운 최고성능 **detector**가 아니다. 추가 **context**가 실제로 사용되는지를 사건·채널별로 감사하는 CHUM(Control-History Utility Mapping) 프로토콜과, 그 결론이 여러 모델 구조와 교란 설정을 넘어 유지되는지를 보여 주는 실증이다.

논문 집필 전 필수 보강으로 정한 TEP **primary consensus sensitivity**도 완료했다. residual block length 5/10/20, conditional draws 1/3/10, TCN/Transformer, seed 42-46을 교차한 390개 조건에서 네 개 locked cell이 모두 사전등록 기준을 통과했다. 따라서 현재 남은 필수 실험은 없다. 추가 seed나 세 번째 데이터셋은 일반성을 넓히는 후속 연구이지, 현재 주장을 성립시키는 선행조건은 아니다.

1. 초록

산업 시계열 이상 탐지에서는 센서 상태뿐 아니라 제어 이력까지 입력하면 성능이 향상될 수 있다. 그러나 단순한 평균 성능 비교는 어떤 사건에서 어떤 제어 채널이 실제 정보를 제공했는지, 향상이 단순한 모델 용량 증가인지, 특정 **architecture**의 inductive bias인지, 또는 비현실적인 feature masking이 만든 분포 이동인지 구분하지 못한다. 본 연구는 이를 해결하기 위해 **Control-History Utility Mapping(CHUM)**을 제안한다. CHUM은 sensor-only 모델(F0), sensor+control 모델(F1), capacity-matched sensor-only 모델(F0-C)을 비교하고, 정상 학습 데이터만으로 구축한 leave-one-channel-out 조건부 대치, 조건별 validation threshold, pre-fault FPR guardrail, seed/run 계층 bootstrap, cross-architecture consensus를 결합해 event-channel별 추가 예측 정보의 유용성을 판정한다.


Tennessee Eastman Process(TEP)의 2,800 runs와 28 faults에서 GRU·TCN·compact Transformer를 비교한 결과, TCN과 Transformer가 동일한 7개 event-level GAIN faults를 식별했다. 더 엄격한 channel-level 판정에서는 F4/XMV10, F19/XMV7, F19/XMV8, F25/XMV2의 네 셀이 두 architecture에서 합의됐다. 기준 설정에서 Δ AUROC는 TCN 0.0555-0.2899, Transformer 0.0531-0.2637이었고 모든 셀에서 5/5 seed가 같은 방향이며 run-level bootstrap CI 하한이 0보다 컸다. Integrated Gradients는 locked primary architecture-fault 셀 8개 중 7개에서 CHUM과 동일한 top channel을 선택했다. HAI 21.03 corrected v2에서는 F1이 F0보다 AUROC +0.0187, AUPRC +0.0306, eTaF1 +0.0267 높았고, 직접 공격된 5개 event-channel 셀에서 조건부 대치 후 score 감소가 3/3 seed에서 반복됐다. 마지막으로 3개 block length와 3개 draw count를 교차한 민감도 실험에서 네 locked cell 모두 두 architecture의 9/9 설정을 통과했다.

이 결과는 제어 이력의 유용성이 사건과 채널에 따라 이질적이며, 일부 조합에서는 모델 구조와 대치 hyperparameter에 강건한 추가 정보를 제공한다는 점을 지지한다. 단, CHUM은 조건부 예측 정보의 감사 방법이며 물리적 인과, controller causality 또는 root-cause identification을 주장하지 않는다.

2. 추현승 교수 연구실 최근 연구 경향과 본 연구의 적합성

왜 CHUM이 추현승 교수 연구실에 맞는가

최근 연구의 응용축은 다르지만, 공통 방법론은 '문맥 활용 → 신뢰성 검증 → 시스템 의사결정'이다



Counts: official lab publication lists, 2024–2026, 65 unique titles; rule-coded from titles, not citation-weighted bibliometrics.

그림 1. 공식 연구실 2024–2026 publication 제목 코딩과 CHUM의 제안 위치

2.1 조사 범위

공식 Superintelligence Laboratory publication 목록의 2024–2026년 자료를 전수 수집했다. Journal/Conference 목록에는 동일 논문이 중복 등록된 경우가 있어 82개 등록, 제목 기준 65편으로 구분했다. 제목 기반 재현 가능한 규칙 코딩 결과, 1차 주제는 6G-네트워크 AI 24편, 의료 AI 21편, 신뢰 AI-RAG-에이전트 6편, 기타 응용 AI 13편, 산업 시계열 이상 진단 1편이었다. 이 수치는 연구 품질이나 인용 영향력이 아니라 연구축의 반복 빈도를 보는 용도다. 원자료는 [deliverables/professor_research/](#)에 보존했다.

2.2 최근 연구에서 반복되는 네 가지 선호

반복 경향	최근 연구의 구체적 형태	CHUM과의 직접 접점
시계열 문맥을 운용 결정에 연결	mobile traffic-mobility 예측을 MEC resource allocation, handover timing, traffic engineering에 사용	제어 이력이 탐지 판단에 주는 추가 정보를 사건-채널별로 분리
신뢰성과 조건 변화에 대한 검증	architecture benchmark, domain robustness, inference confidence, evidence reliability	TCN/Transformer consensus, 조건부 배치 품질, FPR guardrail, sensitivity grid
다중 모델·다중 데이터 환경 비교	의료 AI에서 여러 backbone-dataset-cross-dataset 평가	GRU/TCN/Transformer, TEP/HAI, F0/F1/F0-C 통제 비교
AI-native system과 실용성	NWDAF, emulated B5G testbed, edge resource control, 의료기기 제품화	향후 network telemetry context audit 및 운영 의사결정 모듈로 확장 가능

최근 공저 논문에서도 이 경향이 명확하다.

- Curated Collaborative AI Edge는 B5G/6G RAN에서 network data analytics를 이용해 협업과 자원 제어를 연결한다.

- *Deep Resource Localization*은 지역 traffic pattern을 예측한 뒤 PPO 기반 MEC 자원 할당으로 이어 간다.
- *In-time Conditional Handover*는 과거 mobility context를 이용해 대상 기지국과 dwell time을 함께 예측하고 resource reservation timing을 결정한다.
- *Urban Mobile Data Prediction with GECOS*는 geospatial clustering과 residual TCN-LSTM을 결합하고 real-world traffic data에서 검증한다.
- *Inductive Bias Matters*는 CNN·Transformer·hybrid architecture를 같은 조건에서 비교한다. 이는 CHUM이 단일 architecture의 attribution을 최종 결론으로 삼지 않는 이유와 직접 맞닿는다.
- *Post-training Feature Pruning*은 5개 fundus dataset과 EfficientNetV2·ViT·CoAtNet을 사용하고 cross-dataset transfer까지 확인한다. 이는 성능 최고점보다 compactness와 generalization을 함께 보는 경향을 보여 준다.
- AAMAS 2026의 *EG-RAG*는 evidence graph를 이용한 reliable multi-document reasoning을 다룬다. CHUM은 다른 도메인이지만, “context가 존재한다”와 “신뢰할 수 있게 사용된다”를 구분한다는 문제 구조가 같다.
- EV battery diagnostics의 Mixture-of-Agents 연구는 실제 시계열 로그의 의미적 grouping과 자동 보고를 결합한다. CHUM의 event-channel utility map은 이러한 보고 시스템에 검증 가능한 근거층을 제공할 수 있다.

진행 과제도 같은 방향을 강화한다. 연구실은 2026–2031년 차세대 네트워크 AI Foundation Model, 2024–2028년 6G 통합 지능평면, 2024–2027년 네트워크 상태·구조 학습과 추론 신뢰도·조건 변화 강건성·NWDAF 통합, 망막 Foundation Model 중심의 의료기기 제품화 과제를 수행하고 있다.

2.3 교수님께 가장 설득력 있는 포지셔닝

CHUM을 “산업 공정의 새 모델”로 소개하면 연구실의 핵심 흐름과 연결이 약하다. 다음처럼 정의해야 한다.

CHUM은 industrial multivariate time series를 대상으로 한 trustworthy context-utilization audit다. 추가 context의 유용성을 모델 용량, perturbation-induced distribution shift, false alarms, optimization variability, architecture-specific behavior와 분리한다.

이 문장은 연구실의 네트워크 AI, 신뢰 AI, 의료 AI 검증 성향을 하나의 방법론으로 연결하면서도 현재 실험 범위를 넘지 않는다.

3. 배경

산업 시스템의 관측치는 대체로 두 종류다.

- **Sensor state:** 온도, 압력, 유량, 진동 등 시스템의 상태를 관측한 값
- **Control history:** valve position, setpoint, motor command처럼 시스템에 가해진 조작의 시간 이력

sensor-only 모델은 결과 상태만 보고, sensor+control 모델은 시스템이 어떤 조작을 받았는지까지 본다. 따라서 control history는 이상을 더 일찍 또는 더 명확하게 구분하는 context가 될 수 있다. 하지만 입력 차원을 추가하면 모델 파라미터와 표현력이 함께 바뀌므로, 성능 향상만으로는 제어 이력 자체의 정보라고 결론 낼 수 없다.

또한 단순 feature occlusion은 해당 채널을 0으로 바꿔 학습 분포 밖의 시계열을 만들 수 있다. 이때 성능 저하가 해당 채널의 정보 손실이 아니라 비현실적 입력 충격에서 발생할 수 있고, 정상 구간의 false alarm도 증가한다. 단일 attribution map은 이런 교란을 직접 통제하지 못한다.

4. 문제의식과 연구 공백

4.1 한 문장 문제정의

어떤 산업 이상 사건에서 어떤 제어 채널의 과거 이력이, 모델 용량·분포 교란·오정보율을 통제하
뒤에도 재현 가능한 추가 탐지 정보를 제공하는가?

4.2 기존 접근이 구분하지 못하는 것

1. 전체 평균 성능 향상과 event별 이질성
2. control information과 모델 capacity 증가
3. 실제 정보 손실과 OOD masking 충격
4. 특정 seed·run의 우연과 반복 가능한 효과
5. 특정 architecture의 inductive bias와 구조를 넘는 공통 신호
6. predictive utility와 물리적 인과·root cause

4.3 선행연구 대비 정확한 신규성

FIT·TimeSHAP·learned perturbation 연구는 conditional context와 시계열 attribution의 중요성을 이미 제기했다.
OOD explainability 연구는 feature removal이 비현실적 샘플을 만들 수 있음을 보였다. 따라서 조건부
perturbation 자체를 새로운 원리로 주장하지 않는다.

본 연구의 신규성은 다음 요소를 산업 이상 탐지의 하나의 판정 프로토콜로 결합한 데 있다.

- capacity-matched sensor-only control
- 정상 train-only conditional replacement
- condition-specific validation calibration
- event/run 단위 효과와 hierarchical uncertainty
- pre-fault FPR guardrail
- imputer distribution·lag quality gate
- cross-architecture consensus
- IG 보조 삼각검증
- 외부 HIL 데이터에서의 제한적 반복
- 사전등록 sensitivity grid

5. 연구질문과 가설


ID	연구질문·가설	반증 조건
RQ1 / H1	control history의 이력은 fault/event별로 이질적이다	모든 event에서 유사한 gain이 나타나거나 안정된 GAIN subset이 없음
RQ2 / H2	일부 gain은 capacity 증가로 설명되지 않는다	F1-F0 효과가 F1-F0-C에서 소멸
RQ3 / H3	정상분포 조건부 대체 후에도 특정 channel utility가 남는다	Δ AUROC가 material gate 미달, seed 방향 불안정, CI에 0 포함, FPR guardrail 위반
RQ4 / H4	핵심 channel mapping은 architecture에 강건하다	TCN과 Transformer가 같은 fault에서 합 의하지 못함

ID	연구질문·가설	반증 조건
RQ5 / H5	핵심 결론은 replacement hyperparameter에 강건하다	block length 또는 draw count 변화에서 효과 방향·크기·FPR 기준 붕괴
RQ6 / H6	다른 HIL 환경에서도 제한적 external support가 보인다	HAI corrected v2의 F1 gain과 targeted channel score loss가 seed 간 반복되지 않음

6. 해결 방식: CHUM

CHUM: 입력 추가가 아니라 '실제 정보 유용성'을 감사한다

대안 설명을 하나씩 통제 한 뒤 event-channel 단위로 결론을 낸다



해석 경계: 예측 정보 유용성 ≠ 인과 효과 ≠ 물리적 root cause

그림 2. CHUM의 다섯 단계와 해석 경계

6.1 모델 통제

- **F0**: sensor history만 입력
- **F1**: sensor history와 control history를 함께 입력
- **F0-C**: sensor만 입력하지만 hidden width를 늘려 F1과 parameter 수를 맞춘 capacity control

F1이 F0보다 좋고 F0-C보다도 좋을 때만 control history의 추가 정보 가능성을 인정한다.

6.2 조건부 대체

채널을 0으로 지우지 않는다. 정상 training window에서 대상 control channel을 제외한 나머지 sensor/control history로 해당 채널을 예측하는 leave-one-channel-out ridge imputer를 만든다. 여기에 정상 residual sequence를 block 단위로 sampling해 평균과 분산뿐 아니라 단기 자기상관을 최대한 보존한다. imputer는 test label이나 fault 구간을 학습에 사용하지 않는다.

6.3 utility estimand

architecture **a**, event **e**, control channel **c**에 대해 higher-is-better metric **M**의 utility를 다음처럼 정의한다.

$$U(a,e,c;M) = M(\text{original F1 score}) - M(\text{F1 score after conditional replacement of } c)$$

U > 0이면 해당 channel history를 정상 조건부 대안으로 바꿨을 때 탐지력이 감소했음을 뜻한다. 이는 모델이 해당 **history**에서 조건부 예측 정보를 사용했다는 조작적 정의이지 인과 효과가 아니다.

6.4 판정 gate

TEP channel-level primary 판정은 다음을 모두 요구한다.

- 1. mean ΔAUROC ≥ 0.02
- 2. 5 seeds 중 ≥ 4가 positive
- 3. 최대 절대 pre-fault ΔFPR ≤ 0.005
- 4. paired hierarchical seed → run bootstrap 95% CI 하한 > 0
- 5. imputer의 held-out distribution·lag quality 통과
- 6. TCN과 Transformer 모두 위 기준 통과

이 구조는 큰 숫자 하나가 아니라 효과 크기·반복성·오경보·대치 현실성·모델 합의를 동시에 요구한다.

7. 아이디어 검증 과정

검증 단계	질문	실행	결과
Capacity gate	입력 차원 증가 때문인가	F0/F1/F0-C, 5 seeds, 28 faults	7개 fault gain이 F0-C 대비 유지
Architecture gate	GRU만의 현상인가	TCN·Transformer 30 models	동일 7개 GAIN faults, PASS
Conditional CHUM	zero masking 충격인가	정상-only LOO residual sampling	4개 two-architecture consensus cells
Quality gate	imputer가 비현실적인가	R ² ·variance·Wasserstein·KS·lag 검사	품질 미달 F26/XMV4 실제 제외
Attribution triangulation	CHUM만 그렇게 보이는가	Integrated Gradients	primary top-1 7/8 일치
External support	다른 HIL 환경에서도 보이는가	HAI 21.03 corrected v2	global gain + targeted 5 cells
Integrity audit	누수·버그·집계 오류가 남았는가	overlap 제거, v1 무효화, raw 재계산	18/18 checks PASS
Sensitivity gate	block/draw 고정값 의존인가	3×3×2×5 locked grid	4/4 cells, 두 architecture PASS

핵심은 성공 결과만 남긴 것이 아니다. 예를 들어 TEP F26/XMV4는 raw effect가 컸지만 imputer quality gate를 통과하지 못해 최종 consensus에서 제외했고, HAI v1은 feature column order bug를 발견한 뒤 전체를 무효화했다. corrected v2만 최종 주장에 사용한다.

8. Dataset과 split

두 데이터 환경, 같은 누수 방지 원칙

TEP의 공정 fault에서 방법을 참고하고 HAI 21.03의 HIL attack에서 제한적 외부 지지를 확인



Source: repository split/audit manifests; corrected HAI v2 only. HAI v1은 feature-order bug로 무효화 제외.

그림 3. TEP·HAI 데이터 환경과 누수 방지 protocol

항목	TEP	HAI 21.03
환경	simulated chemical process faults	hardware-in-the-loop cyber-physical attacks
규모	2,800 runs, 28 faults	8 episodes, 1,323,608 rows, 50 global attack events
변수 역할	41 XMEAS sensors, 11 XMV controls	29 sensor targets, 28 active control histories
분할	run 단위 1,792/448/560 train/validation/test	episode/time-aware 분리, train 내부 80/20
반복	seeds 42–46	seeds 42–44
주요 위험	동일 run window leakage	train–test telemetry exact overlap, role/target ambiguity
대응	run-before-window split	exact-overlap 43,202 train rows 제거, role/target audit

TEP는 방법 개발과 strict consensus의 주 근거다. HAI는 산업·HIL 맥락의 외부 지지지만, 모든 process subgroup과 모든 비공격 control history에 대한 보편 검증으로 해석하지 않는다.

9. 전처리 방식

9.1 공통 원칙

- split을 먼저 확정하고 window를 생성한다.
- scaler와 imputer는 training 정상 데이터에만 fit한다.

- 3. threshold는 validation 정상 score percentile로만 정한다.
- 4. 각 perturbation condition의 score distribution에 맞춰 validation threshold를 다시 보정한다.
- 5. test label은 metric 계산에만 사용하고 training·scaling·imputation·threshold selection에 사용하지 않는다.

9.2 TEP

- window length: 20
- fault onset: sample 600
- channel 분석 구간: sample 400–900
- threshold: validation-normal 99th percentile
- alarm: threshold 3회 연속 초과
- conditional replacement: LOO ridge prediction + normal residual block sampling
- 기준 설정: residual block 20, draws 3

9.3 HAI

- window length: 30
- train stride: 10
- threshold: validation-normal 99.5th percentile
- alarm: threshold 3회 연속 초과
- official time-aware eTaF1을 AUROC·AUPRC와 함께 사용
- point-role·attack-target manifest를 먼저 검증
- exact duplicate telemetry가 test와 겹친 43,202 training rows 제거

10. 모델링

Architecture	목적	공정한 비교 장치
GRU	최초 event-level 현상 확인	F0 23,209 / F1 25,321 / F0-C 25,473 parameters
two-layer TCN	convolutional temporal inductive bias	F0 8,425 / F1 9,481 / F0-C 9,526 parameters
compact two-layer Transformer	attention 기반 구조 검증	F0/F0-C 20,489 / F1 20,841 parameters, 1.7% 차이
HAI compact sequence forecaster	외부 HIL 반복	F1 30,941 / F0-C 31,021 parameters, 약 0.26% 차이

본 논문은 architecture 최고점 경쟁을 하지 않는다. 동일 split·preprocessing·threshold 원칙 아래 서로 다른 inductive bias에서 결론의 방향이 반복되는지를 검증한다.

11. 실험 설계와 평가 지표

11.1 실험 행렬

실험	단위	모델/조건	반복·규모	판정 목적
TEP capacity	fault	F0/F1/F0-C × GRU	5 seeds × 28 faults	event heterogeneity와 capacity 통제

실험	단위	모델/조건	반복·규모	판정 목적
TEP architecture	fault	F0/F1/F0-C × TCN/Transformer	30 trained models	구조를 넘는 event gain
TEP G3 CHUM	fault-channel	conditional/LOO-sample/zero	340 tasks, 9,520 fault rows, 190,400 run rows	channel consensus
IG baseline	architecture-fault-channel	Integrated Gradients	880 rows	보조 attribution 일치
HAI external v2	global/event	F0/F1/F0-C	9 models, 450 event rows	제한적 외부 지지
HAI conditional	attack-channel	LOO-sample/zero	171 tasks, 8,550 event rows	직접 공격 channel utility
Primary sensitivity	locked cell	block 5/10/20 × draws 1/3/10	390 tasks, 7,800 run rows	고정값 의존성 반증

11.2 지표

- sample ranking: AUROC, AUPRC
- event-aware detection: eTaF1, detected-run ratio, detection delay
- safety guardrail: pre-fault FPR 및 condition 간 절대 변화
- attribution effect: original-conditional Δ AUROC/ Δ AUPRC, normalized event-score loss
- uncertainty: 2,000회 paired hierarchical seed → run/event bootstrap
- consistency: positive seed count, architecture consensus, IG top-1 agreement
- imputer quality: predictive R^2 , SD ratio, mean shift, lag-1 error, train-range violation, Wasserstein, KS

12. 완료된 실험 결과

12.1 TEP event-level architecture robustness

TCN과 Transformer는 동일한 7개 GAIN faults 4, 7, 19, 23, 24, 25, 26을 식별했다. 모든 fault에서 두 architecture 모두 5/5 seed가 같은 방향이었다.

Fault	TCN F1-F0-C Δ AUROC	Transformer F1-F0-C Δ AUROC	해석
4	+0.1663	+0.1087	두 구조에서 material gain
7	+0.4880	+0.4845	가장 큰 공통 gain
19	+0.1783	+0.1970	안정적 공통 gain
23	+0.0300	+0.0234	GRU strict set과 달라 architecture-dependent로 표시
24	+0.1091	+0.0877	안정적 공통 gain
25	+0.2916	+0.2776	큰 공통 gain
26	+0.3868	+0.4154	event gain은 크지만 channel quality gate에서 주의

12.2 TEP channel-level consensus

TEP: 4개 핵심 event-channel이 두 아키텍처에서 모두 재현

각 셀 5/5 seeds 동일 방향 · hierarchical run CI 하한 > 0 · $|\Delta FPR| \leq 0.00125$




그림 4. TEP locked cell의 두 architecture ΔAUROC

Locked cell	TCN ΔAUROC	Transformer ΔAUROC	TCN CI 하한	Transformer CI 하한	기준 설정 최대 abs(ΔFPR)
F4/XMV10	+0.1653	+0.1055	+0.1241	+0.0882	0.00075
F19/XMV7	+0.1355	+0.1237	+0.1270	+0.1135	0.00075
F19/XMV8	+0.0555	+0.0531	+0.0505	+0.0467	0.00050
F25/XMV2	+0.2899	+0.2637	+0.2850	+0.2547	0.00125

모든 architecture-cell에서 5/5 seed가 positive였다. F26/XMV4는 raw effect가 컸지만 imputer distribution quality를 만족하지 못해 최종 셀에서 제외했다. 즉 gate가 형식적 장식이 아니라 실제 탈락 기준으로 작동했다.

12.3 IG 교차검증


집합	셀 수	Spearman 중앙값	top-1 일치
Locked primary	8	0.5434	7/8, 87.5%
Negative/exploratory	8	0.1005	1/8, 12.5%

IG와 CHUM은 estimand가 다르므로 동일값을 기대하지 않는다. 중요한 점은 모든 fault에서 자동으로 일치한 것이 아니라 CHUM 효과가 강한 primary 집합에서만 높은 top-1 합의가 나타났다는 것이다.

12.4 HAI 21.03 corrected v2

HAI 21.03: 다른 HIL 환경에서도 제한적 외부 지지

Corrected v2 : 모든 전역 차이는 3/3 seeds 동일 방향 · 5개 targeted cells도 3/3 방향 일치



Interpretation: external support, not universal process-wise or causal validation. Source: final evidence recomputation at commit bc6166f

그림 5. HAI corrected v2의 전역 및 targeted-channel 외부 지지

Variant	Parameters	AUROC	AUPRC	eTaF1	FPR	평균 지연
F0	26,909	0.8331	0.4743	0.5895	0.00267	47.48
F0-C	31,021	0.8301	0.4663	0.5807	0.00264	49.18
F1	30,941	0.8518	0.5049	0.6162	0.00270	43.74

- F1-F0: AUROC **+0.018745**, AUPRC **+0.030608**, eTaF1 **+0.026722**
- F1-F0-C: AUROC **+0.021744**, AUPRC **+0.038605**, eTaF1 **+0.035477**
- 모든 전역 차이는 3/3 seed에서 같은 방향
- 직접 공격된 5개 event-channel 셀의 normalized score loss: **+0.0588~+0.2146**, 모두 3/3 seed positive

HAI 결과는 external support다. attack target이 직접 control point인 셀을 포함하므로 공격받지 않은 control context의 보편적 유용성까지 입증하지 않는다.

13. 새로 완료한 최종 민감도 실험

13.1 사전 고정 설계

- locked cells: F4/XMV10, F19/XMV7, F19/XMV8, F25/XMV2
- block length: 5, 10, 20
- conditional draws: 1, 3, 10
- architecture: TCN, Transformer
- seeds: 42-46
- 기존 checkpoint 재사용, 재학습 없음
- paired hierarchical bootstrap 2,000회

architecture-cell 하나가 robust하려면 다음을 요구했다.

- positive mean Δ AUROC: 9/9 settings
- material Δ AUROC ≥ 0.02 : 최소 8/9
- positive seeds $\geq 4/5$: 최소 8/9
- hierarchical run CI 하한 > 0 : 최소 8/9
- absolute FPR shift ≤ 0.005 : 9/9
- 기존 설정 block 20/draws 3이 모든 setting gate 통과

최종 PASS는 네 셀 모두에서 두 architecture가 robust해야 한다.

13.2 결과




그림 6. 3×3 replacement sensitivity의 architecture-cell별 Δ AUROC 범위

PASS — 4/4 locked cells가 두 architecture에서 통과했다. 실제로 8개 architecture-cell 모두 positive/material/seed-stable/CI-positive/FPR guardrail을 9/9 설정에서 만족했다.

Architecture · cell	9개 설정 Δ AUROC 범위	최악 $\text{abs}(\Delta\text{FPR})$	결과
TCN · F4/XMV10	+0.16527~+0.16534	0.00075	PASS
Transformer · F4/XMV10	+0.10550~+0.10556	0.00075	PASS

Architecture · cell	9개 설정 Δ AUROC 범위	최악 abs(Δ FPR)	결과
TCN · F19/XMV7	+0.13541–+0.13579	0.00150	PASS
Transformer · F19/XMV7	+0.12356–+0.12388	0.00075	PASS
TCN · F19/XMV8	+0.05543–+0.05554	0.00050	PASS
Transformer · F19/XMV8	+0.05304–+0.05310	0.00075	PASS
TCN · F25/XMV2	+0.28979–+0.29017	0.00125	PASS
Transformer · F25/XMV2	+0.26343–+0.26442	0.00150	PASS

최악 설정에서도 최소 Δ AUROC는 **+0.05304**로 material gate **+0.02**의 2.65배였다. 이 결과는 본 논문의 중심 결론이 block length나 stochastic draw count의 한 고정값에서만 생겼다는 반론을 직접 차단한다.

14. 연구 무결성과 재현성

논문 집필 전 증거 패키지: 핵심 공격 경로를 모두 차단

모든 PASS는 raw table 재계산과 사전 고정 gate를 기준으로 한다

용량 효과인가?	F1 vs F0-C	PASS	parameter gap 0.26% (HAI); event gain 반복
특정 구조만의 현상인가?	GRU · TCN · Transformer	PASS	TEP gain pattern + 4-cell two-architecture consensus
비현실적 masking 효과인가?	normal conditional replacement	PASS	imputer quality + condition calibration + FPR guardrail
seed-run 우연인가?	5/3 seeds + hierarchical CI	PASS	primary cells 5/5; HAI support 3/3
고정 hyperparameter 의존인가?	3 block × 3 draws	PASS	4/4 cells × 2 architectures; 9/9 strict settings
외부 환경에서도 보이나?	HAI 21.03 corrected v2	SUPPORT	global metrics + 5 directly attacked channel cells

남은 경계: 인과-물리적 root cause-모든 산업/네트워크로의 보편 일반화는 주장하지 않음.

그림 7. 논문 집필 전 핵심 반론과 대응 evidence scorecard

- TEP/HAI 모두 split 전에 window를 섞지 않는다.
- scaler·imputer·threshold는 train/validation만 사용한다.
- HAI train–test exact overlap 43,202 rows를 제거했다.
- HAI feature-order bug가 발견된 v1은 전량 무효화하고 최종 집계에서 격리했다.
- G3 340 tasks, IG 880 rows, HAI v2 9 models, HAI conditional 171 tasks를 key duplicate 없이 완료했다.
- 기존 최종 raw evidence validator 18/18 checks가 PASS했다.
- 새 sensitivity는 config·runner·analyzer·manifest·raw tables·2,000회 bootstrap 요약을 보존했다.
- 연구실 publication 전수표와 분류 규칙도 코드로 재생성 가능하다.

15. 핵심 기여

1. 문제정의 기여: “control을 추가하면 성능이 오르는가”를 “어떤 event–channel에서 control history가 조건부 정보를 제공하는가”로 바꾼다.

2. **방법 기여:** capacity control, 정상분포 대치, condition calibration, FPR guardrail, hierarchical uncertainty, architecture consensus를 하나의 audit protocol로 결합한다.
3. **실증 기여:** TEP에서 4개 architecture-robust channel cells와 7개 event-level gain faults를 확인한다.
4. **강건성 기여:** 3×3 replacement sensitivity에서 4/4 locked cells가 두 architecture에서 유지됨을 보인다.
5. **외부 지지:** HAI corrected v2에서 global gain과 5개 directly attacked control cells의 conditional support를 제시한다.
6. **연구 관행 기여:** 실패한 imputer cell과 잘못된 HAI v1을 숨기지 않고 exclusion rule과 invalidation trail을 공개한다.

16. 의의와 한계

16.1 의의

- 운영자가 모든 control channel을 동일하게 설명·감시할 필요 없이 event별 핵심 context를 좁힐 수 있다.
- attribution을 heatmap 하나가 아니라 탐지력·손실·오경보·대치 품질·모델 함의로 검증한다.
- 네트워크 AI에서도 telemetry/context를 foundation model이나 NWDAF에 넣기 전에 실제 utility를 감사하는 형태로 확장할 수 있다.
- 의료 AI의 multi-backbone·cross-dataset 검증 철학을 산업 시계열 context 분석으로 옮긴다.

16.2 한계

- conditional replacement는 observational test이며 intervention이 아니다.
- 선택된 channel은 fault의 물리적 원인이나 최적 제어변수라는 뜻이 아니다.
- TEP 5 seeds는 최적화 변동성 반복이지 독립 dataset 5개가 아니다. 양측 exact sign-flip test 최소 p 값은 0.0625이므로 seed-level $p < 0.05$ 를 주장하지 않는다.
- HAI는 3 seeds이고 직접 공격 control 셀을 포함하므로 external evidence의 범위가 제한된다.
- imputer quality gate를 통과하지 못하는 channel에는 CHUM의 결론을 내리지 않는다.
- 전체 산업·통신·의료 도메인으로의 보편 일반화는 후속 검증이 필요하다.

17. 발전 가능성

17.1 논문 이후 1순위: Network Context Utility Audit

6G/NWDAF traffic·mobility·resource telemetry를 state와 action/context로 분리하고, time-series foundation model 또는 network predictor가 어떤 context를 실제로 사용하는지 CHUM gate로 감사한다. 연구실의 NFM·6G 지능 평면·추론 신뢰도 과제와 가장 직접적으로 연결된다.

17.2 2순위: Drift-aware online CHUM

정상분포 imputer와 utility map의 변화를 online drift signal로 이용한다. channel utility가 붕괴하거나 FPR이 이동할 때 recalibration 또는 human review를 요청한다.

17.3 3순위: Causal/digital-twin extension

TEP simulator나 실제 digital twin에서 명시적 intervention을 수행해 predictive utility와 causal effect를 분리한다. 이것이 root-cause 주장으로 넘어가기 위한 필수 단계다.

17.4 4순위: Evidence-grounded automated reporting

CHUM의 event-channel evidence와 uncertainty를 graph 또는 structured evidence로 만들어 EV/industrial diagnostic LLM의 보고 근거로 사용한다. LLM은 결론을 생성하되, utility gate를 통과하지 못한 channel은 근거로 제시하지 않도록 제한한다.

18. 논문 집필 구조

1. **Introduction** — 평균 성능 비교가 숨기는 event-level heterogeneity와 context-utilization 문제
2. **Related Work** — controller-aware detection, time-series attribution, conditional perturbation, OOD explainability, model multiplicity
3. **Problem Formulation** — F0/F1/F0-C와 conditional utility estimand
4. **CHUM Method** — imputer, calibration, FPR, uncertainty, consensus gate
5. **Datasets and Integrity Protocol** — TEP/HAI, roles, splits, overlap removal, invalidated v1
6. **Event-Level Results** — capacity and architecture gates
7. **Channel-Level Results** — conditional CHUM, imputer audit, IG triangulation
8. **External and Sensitivity Validation** — HAI corrected v2, 3×3 locked sensitivity
9. **Discussion** — 연구실 방향과의 연결, 운영적 의미, 한계
10. **Conclusion** — 조건부 예측 정보의 범위 안에서 최종 주장

19. 집필 일정과 종료 기준

주차	산출물	종료 기준
1주차	Introduction, RQ, Contribution, Methods 도식	핵심 claim과 금지 claim을 지도교수와 잠금
2주차	Dataset/Preprocessing/Model/Experiment, 표·그림	모든 수치가 raw/summary table과 일치
3주차	Results, Discussion, Related Work	각 주장에 effect·uncertainty·guardrail·limitation 연 결
4주차	전체 교정, appendix, reproducibility package	표/그림 번호·source·config·commit 일 치, 문장 과장 제거

추가 실험은 교수님이 현재 claim보다 더 강한 claim을 요구할 때만 수행한다.

- seed-level $p < 0.05$ 가 필요하면 TEP seed를 늘린다.
- 공격받지 않은 control context의 외부 일반화가 필요하면 새 HIL/실데이터를 추가한다.
- root cause를 주장하려면 intervention 또는 digital twin causal experiment를 새 연구로 설계한다.

20. 지도교수에게 요청할 세 가지 결정

1. 문제를 “제어 이력 추가의 평균 효과”가 아니라 “event-channel별 조건부 utility”로 확정할 것인가?
2. 주 기여를 새 detector가 아니라 CHUM audit protocol과 architecture-robust evidence로 둘 것인가?
3. 현재 claim boundary를 유지한 채 본문 집필을 시작하고, 더 강한 causal/generalization claim은 후속 연구로 분리할 것인가?

권고 받은 세 항목 모두 예다.

21. 주요 출처

교수·연구실

- Superintelligence Laboratory: <http://monet.skku.edu/main/>
- 연구 분야: http://monet.skku.edu/main/bbs/board.php?bo_table=areas
- 진행 과제: http://monet.skku.edu/main/bbs/board.php?bo_table=projects
- 2026 Journal 목록: http://monet.skku.edu/main/bbs/board.php?bo_table=public1&sca=2026
- 2026 Conference 목록: http://monet.skku.edu/main/bbs/board.php?bo_table=public2&sca=2026
- SKKU Pure profile: <https://pure.skku.edu/en/persons/hyunseung-choo/>
- Curated Collaborative AI Edge: <https://pure.skku.edu/en/publications/curated-collaborative-ai-edge-with-network-data-analytics-for-b5g/>
- Deep Resource Localization: <https://pure.skku.edu/en/publications/deep-resource-localization-with-traffic-prediction-for-adaptive-m/>
- In-time Conditional Handover: <https://pure.skku.edu/en/publications/in-time-conditional-handover-for-b5g6g/>
- GECOS: <https://pure.skku.edu/en/publications/urban-mobile-data-prediction-with-geospatial-clustering-and-dual-/>
- Post-training Feature Pruning, CVPR 2026: https://openaccess.thecvf.com/content/CVPR2026/html/Pham_Post-training_Feature_Pruning_for_Fundus_Images_Classification_CVPR_2026_paper.html
- EG-RAG, AAMAS 2026 proceedings: <https://www.ifaamas.org/Proceedings/aamas2026/forms/contents.htm>
- Mixture-of-Agents EV diagnostics: https://filuta.ai/papers/CompAI_2025_paper_3.pdf

핵심 방법 선행연구

- FIT: <https://proceedings.neurips.cc/paper/2020/hash/08fa43588c2571ade19bc0fa5936e028-Abstract.html>
- TimeSHAP: <https://arxiv.org/abs/2012.00073>
- OOD explainability: <https://proceedings.neurips.cc/paper/2021/hash/1def1713ebf17722cbe300cfc1c88558-Abstract.html>
- Learning Perturbations: <https://proceedings.mlr.press/v202/enguehard23a.html>
- Rashomon Importance Distribution: https://proceedings.neurips.cc/paper_files/paper/2023/hash/1403ab1a427050538ec59c7f570aec8b-Abstract-Conference.html
- Quantitative explanation evaluation: <https://proceedings.mlr.press/v206/jethani23a.html>

최종 판정

MANUSCRIPT-READY. 현재 증거는 “일부 산업 이상 사건에서 특정 control history가 조건부 예측 정보를 제공하며, 그 mapping이 capacity·FPR·distribution quality·architecture·replacement hyperparameter 통제 후에도 반복된다”는 석사논문 수준의 주장을 지지한다. 다음 행동은 새 실험 탐색이 아니라 제목·RQ·claim boundary를 지도교수와 잠그고 본문 집필을 시작하는 것이다.