

산업 시계열 이상 탐지에서 제어 이력의 조건부 유용성 감사

CHUM: Architecture-Robust Auditing of Control-History Utility for Industrial Time-Series Anomaly Detection

검토용 논문 초안 · 2026-09-21 작성 / 2026-10-02 후속 결과·범위 보충

기존 연구의 방법과 결과를 논문 순서로 재구성한 초안이다. 제목과 최종 주장에 대한 지도교수 승인 또는 학교 제출 완료를 뜻하지 않는다. 2026-09-21 에 보존 원자료 기반 18 개 검증, 224-cell 다중비교, 민감도 bootstrap 을 재실행했다. 모델 재학습과 원시 telemetry 전처리는 재실행하지 않았다.

초록

산업 이상 탐지에서 제어 이력의 추가 효과를 평균 성능만으로 평가하면 사건별 이질성, 모델 용량, 비현실적인 입력 대치와 오경보의 영향을 구분하기 어렵다. 본 연구는 Control-History Utility Mapping(CHUM)을 통해 센서 전용 모델, 센서-제어 결합 모델, 용량을 맞춘 센서 전용 대조군을 비교하고, 정상 데이터 기반 조건부 대치와 대치 품질·오경보·반복성·모델 구조 합의를 결합한다. TEP 의 28 개 fault 에서 TCN 과 Transformer 는 동일한 7 개 fault 의 event-level gain 을 보였다. 채널 수준에서는 F4/XMV10, F19/XMV7, F19/XMV8, F25/XMV2 가 두 구조의 판정 기준을 충족했다. 대치 품질을 통과한 224 개 후보에 BH 보정을 적용한 결과 네 셀이 모두 $q=0.05$ 에서 유지됐다. 세 residual block 길이와 세 draw 수를 교차한 민감도 분석에서도 네 셀이 유지됐다. HAI corrected v2 에서는 전역 AUROC 와 AUPRC 개선 및 직접 공격된 5 개 채널 셀의 score 감소가 관찰됐으나, 3 개 seed 와 직접 공격 조건의 제한 때문에 외부 지지로 한정한다. CHUM 은 평가한 모델과 대치 분포 아래의 예측 유용성을 감사하며 물리적 원인이나 인과적 제어 효과를 식별하지 않는다.

주요어: 산업 시계열, 이상 탐지, 제어 이력, 조건부 대치, 설명 가능성, 강건성

1. 서론

산업 시계열에는 센서가 관측한 상태와 제어 시스템의 조작 이력이 함께 기록된다. 제어 이력은 현재 센서 상태만으로는 구분하기 어려운 동작 조건을 제공할 수 있다. 그러나 제어 변수를 입력에 추가해

평균 탐지 성능이 개선됐다는 사실만으로 어느 사건에서 어느 채널을 모델이 활용했는지는 알 수 없다. 입력 차원과 함께 변한 모델 용량도 분리해야 한다.

채널을 제거한 뒤 탐지력이 감소하는지 측정하는 접근에도 교란이 있다. 비현실적인 대치 값은 정상 구간의 score 를 변화시키고 오경보를 증가시킬 수 있다. 또한 한 모델의 중요도가 다른 구조에서도 유지된다는 보장은 없다. 따라서 유용성은 효과크기 하나가 아니라 대치 품질, 정상 구간 변화, 반복 실행의 안정성과 함께 평가해야 한다.

본 연구의 질문은 어떤 사건과 제어 채널에서 이러한 통제 뒤에도 추가 탐지 정보가 유지되는가이다. 이를 위해 CHUM 평가 프로토콜을 구성하고 TEP 에서 주 분석을, HAI 21.03 에서 제한적 외부 검증을 수행했다. 기여는 새 검출기의 최고 성능이 아니라 용량 대조군, 정상 조건부 대치, 조건별 임계값 보정, FPR 제한과 구조 간 합의를 결합한 감사 절차 및 그 실증이다.

2. 관련 연구

FIT 는 시간에 따른 예측 분포 변화를 통해 다변량 시계열 관측의 중요도를 평가하며 시간 의존적 분포 변화를 통제할 필요성을 다룬다. TimeSHAP 은 KernelSHAP 을 순차 입력으로 확장해 feature-timestep-cell 수준 attribution 을 산출한다. CHUM 은 산업 fault 별 탐지력 손실과 오경보 제한을 함께 평가한다는 점에서 평가 대상이 다르다. [1, 2]

Hase 등의 연구는 feature removal 로 생성된 분포 밖 입력이 중요도 설명과 평가를 왜곡할 수 있음을 다룬다. CHUM 은 정상 데이터로 학습한 대치와 품질 검사에 이 문제의식을 반영한다. 다만 정상 구간 품질 검사를 통과했다는 사실이 이상 구간에서 정확한 조건부 분포를 복원했다는 증명은 아니다. [3]

Integrated Gradients 는 sensitivity 와 implementation invariance 를 중심으로 제안된 attribution 방법이다. CHUM 의 탐지 utility 와 동일한 양을 추정하지 않으므로 채널 순위의 보조 비교로 사용한다. FIT 나 TimeSHAP 대비 성능 우위를 실험한 것이 아니며 조건부 대치 자체의 최초 제안도 주장하지 않는다. [4]

3. 연구질문과 반증 조건

ID	연구질문·가설	반증 조건
RQ1 / H1	control history 의 이득은 fault/event 별로 이질적이다	모든 event 에서 유사한 gain 이 나타나거나 안정된 GAIN subset 이 없음

ID	연구질문·가설	반증 조건
RQ2 / H2	일부 gain 은 capacity 증가로 설명되지 않는다	F1-F0 효과가 F1-F0-C 에서 소멸
RQ3 / H3	정상분포 조건부 대치 후에도 특정 channel utility 가 남는다	Δ AUROC 가 material gate 미달, seed 방향 불안정, CI 에 0 포함, FPR guardrail 위반
RQ4 / H4	핵심 channel mapping 은 architecture 에 강건하다	TCN 과 Transformer 가 같은 fault 에서 합의하지 못함
RQ5 / H5	핵심 결론은 replacement hyperparameter 에 강건하다	block length 또는 draw count 변화에서 효과 방향·크기·FPR 기준 붕괴
RQ6 / H6	다른 HIL 환경에서도 제한적 external support 가 보인다	HAI corrected v2 의 F1 gain 과 targeted channel score loss 가 seed 간 반복되지 않음

4. CHUM 방법

4.1 모델 통제

- **F0**: sensor history 만 입력
- **F1**: sensor history 와 control history 를 함께 입력
- **F0-C**: sensor 만 입력하지만 hidden width 를 늘려 F1 과 parameter 수를 맞춘 capacity control

F1 이 F0 보다 좋고 F0-C 보다도 좋을 때만 control history 의 추가 정보 가능성을 인정한다.

4.2 조건부 대치

채널을 0 으로 지우지 않는다. 정상 training window 에서 대상 control channel 을 제외한 나머지 sensor/control history 로 해당 채널을 예측하는 leave-one-channel-out ridge imputer 를 만든다. 여기에 정상 residual sequence 를 block 단위로 sampling 해 평균과 분산뿐 아니라 단기 자기상관을 최대한 보존한다. imputer 는 test label 이나 fault 구간을 학습에 사용하지 않는다.

4.3 utility estimand

architecture **a**, event **e**, control channel **c** 에 대해 higher-is-better metric **M** 의 utility 를 다음처럼 정의한다.

$$U(a,e,c;M) = M(\text{original F1 score}) - M(\text{F1 score after conditional replacement of } c)$$

$U > 0$ 이면 해당 channel history 를 정상 조건부 대안으로 바꿨을 때 탐지력이 감소했음을 뜻한다. 이는 모델이 해당 history 에서 조건부 예측 정보를 사용했다는 조작적 정의이지 인과 효과가 아니다.

4.4 판정 gate

TEP channel-level primary 판정은 다음을 모두 요구한다.

1. mean $\Delta\text{AUROC} \geq 0.02$
2. 5 seeds 중 ≥ 4 가 positive
3. 최대 절대 pre-fault $\Delta\text{FPR} \leq 0.005$
4. paired hierarchical seed→run bootstrap 95% CI 하한 > 0
5. imputer 의 held-out distribution-lag quality 통과
6. TCN 과 Transformer 모두 위 기준 통과

이 구조는 큰 숫자 하나가 아니라 효과 크기·반복성·오경보·대치 현실성·모델 합의를 동시에 요구한다.

5. 데이터와 분할

항목	TEP	HAI 21.03
환경	simulated chemical process faults	hardware-in-the-loop cyber-physical attacks
규모	2,800 runs, 28 faults	8 episodes, 1,323,608 rows, 50 global attack events
변수 역할	41 XMEAS sensors, 11 XMV controls	29 sensor targets, 28 active control histories
분할	run 단위 1,792/448/560 train/validation/test	episode/time-aware 분리, train 내부 80/20
반복	seeds 42–46	seeds 42–44
주요 위험	동일 run window leakage	train–test telemetry exact overlap, role/target ambiguity
대응	run-before-window split	exact-overlap 43,202 train rows 제거, role/target audit

TEP 는 방법 개발과 strict consensus 의 주 근거다. HAI 는 산업·HIL 맥락의 외부 지지지만, 모든 process subgroup 과 모든 비공격 control history 에 대한 보편 검증으로 해석하지 않는다.

6. 전처리와 평가 구간

6.1 공통 원칙

1. split 을 먼저 확정하고 window 를 생성한다.
2. scaler 와 imputer 는 training 정상 데이터에만 fit 한다.
3. threshold 는 validation 정상 score percentile 로만 정한다.
4. 각 perturbation condition 의 score distribution 에 맞춰 validation threshold 를 다시 보정한다.
5. test label 은 metric 계산에만 사용하고 training-scaling-imputation-threshold selection 에 사용하지 않는다. 이 구분이 미사용 평가를 뜻하지는 않는다. 기존 TEP test 는 후속 방법 개발에서 반복 관찰되었으므로 후속 결과에서는 개발 벤치마크이며 새로운 holdout 이 아니다.

6.2 TEP

- window length: 20
- fault onset: sample 600
- channel 분석 구간: sample 400–900
- threshold: validation-normal 99th percentile
- alarm: threshold 3 회 연속 초과
- conditional replacement: LOO ridge prediction + normal residual block sampling
- 기준 설정: residual block 20, draws 3

6.3 HAI

- window length: 30
- train stride: 10
- threshold: validation-normal 99.5th percentile
- alarm: threshold 3 회 연속 초과
- official time-aware eTaF1 을 AUROC-AUPRC 와 함께 사용
- point-role-attack-target manifest 를 먼저 검증
- exact duplicate telemetry 가 test 와 겹친 43,202 training rows 제거

7. 모델과 용량 통제

Architecture	목적	공정한 비교 장치
GRU	최초 event-level 현상 확인	F0 23,209 / F1 25,321 / F0-C 25,473 parameters
two-layer TCN	convolutional temporal inductive bias	F0 8,425 / F1 9,481 / F0-C 9,526 parameters
compact two-layer Transformer	attention 기반 구조 검증	F0/F0-C 20,489 / F1 20,841 parameters, 1.7% 차이
HAI compact sequence forecaster	외부 HIL 반복	F1 30,941 / F0-C 31,021 parameters, 약 0.26% 차이

본 논문은 architecture 최고점 경쟁을 하지 않는다. 동일 split-preprocessing-threshold 원칙 아래 서로 다른 inductive bias 에서 **결론의 방향이 반복되는지**를 검증한다.

8. 실험 설계와 평가 지표

8.1 실험 행렬

실험	단위	모델/조건	반복·규모	판정 목적
TEP capacity	fault	F0/F1/F0-C × GRU	5 seeds × 28 faults	event heterogeneity 와 capacity 통제
TEP architecture	fault	F0/F1/F0-C × TCN/Transformer	30 trained models	구조를 넘는 event gain
TEP G3 CHUM	fault-channel	conditional/LOO-sample/zero	340 tasks, 9,520 fault rows, 190,400 run rows	channel consensus
IG baseline	architecture-fault-channel	Integrated Gradients	880 rows	보조 attribution 일치
HAI external v2	global/event	F0/F1/F0-C	9 models, 450 event rows	제한적 외부 지지

실험	단위	모델/조건	반복·규모	판정 목적
HAI conditional	attack-channel	LOO-sample/zero	171 tasks, 8,550 event rows	직접 공격 channel utility
Primary sensitivity	locked cell	block 5/10/20 × draws 1/3/10	390 tasks = 360 perturbation + 30 shared original, 7,800 run rows	고정값 의존성 반증

8.2 지표

- sample ranking: AUROC, AUPRC
- event-aware detection: eTaF1, detected-run ratio, detection delay
- safety guardrail: pre-fault FPR 및 condition 간 절대 변화
- attribution effect: original–conditional Δ AUROC/ Δ AUPRC, normalized event-score loss
- uncertainty: 2,000 회 paired hierarchical seed→run/event bootstrap
- consistency: positive seed count, architecture consensus, IG top-1 agreement
- imputer quality: predictive R^2 , SD ratio, mean shift, lag-1 error, train-range violation, Wasserstein, KS

9. 결과

9.1 TEP event-level architecture robustness

TCN 과 Transformer 는 동일한 7 개 GAIN faults 4, 7, 19, 23, 24, 25, 26 을 식별했다. 해당 일곱 GAIN fault 에서 두 architecture 모두 5/5 seed 가 같은 방향이었다.

Fault	TCN F1–F0-C Δ AUROC	Transformer F1–F0-C Δ AUROC	해석
4	+0.1663	+0.1087	두 구조에서 material gain
7	+0.4880	+0.4845	가장 큰 공통 gain
19	+0.1783	+0.1970	안정적 공통 gain
23	+0.0300	+0.0234	GRU strict set 과 달라 architecture-dependent 로 표시

Fault	TCN F1–F0-C Δ AUROC	Transformer F1–F0-C Δ AUROC	해석
24	+0.1091	+0.0877	안정적 공통 gain
25	+0.2916	+0.2776	큰 공통 gain
26	+0.3868	+0.4154	event gain 은 크지만 channel quality gate 에서 주의

GRU 의 대표 seed-42 event-level 결과도 숨기지 않는다.

GRU variant	입력	AUROC	AUPRC	탐지 지연
F0	XMEAS	0.7508	0.8995	51.9
F1	XMEAS+XMV	0.8196	0.9312	24.6
F0-C	XMEAS, capacity-matched	0.7493	0.8989	49.4

F0→F1 의 event-level 방향은 model seed 42–44 에서 반복됐고 F0-C 는 이득을

재현하지 못했다. 이는 추가 예측 정보의 근거이지 인과적 controller effect 의

근거가 아니다.

9.2 TEP channel-level consensus

Locked cell	TCN Δ AUROC	Transformer Δ AUROC	TCN CI 하한	Transformer CI 하한	기준 설정 최대 $abs(\Delta FPR)$
F4/XMV10	+0.1653	+0.1055	+0.1241	+0.0882	0.00075
F19/XMV7	+0.1355	+0.1237	+0.1270	+0.1135	0.00075
F19/XMV8	+0.0555	+0.0531	+0.0505	+0.0467	0.00050
F25/XMV2	+0.2899	+0.2637	+0.2850	+0.2547	0.00125

모든 architecture–cell 에서 5/5 seed 가 positive 였다. **F26/XMV4** 는 raw effect 가 컸지만 imputer distribution quality 를 만족하지 못해 최종 셀에서 제외했다. 즉 gate 가 형식적 장식이 아니라 실제 탈락 기준으로 작동했다.

후보 분모와 BH-FDR

G3 는 28 faults × archive XMV 11 개 = 308 개 raw cell 을 전수 계산했다.

XMV5-XMV9 는 상수이고 XMV4 는 primary LOO-residual imputer quality gate 를

통과하지 못했다. 따라서 confirmatory candidate family 는 28 faults ×

8 reliable channels = **224 cells** 다. 20 개 held-out run 을 paired cluster 로

삼아 두 architecture 와 5 seeds 의 delta 를 평균한 뒤 200,000 회 단측

sign-flip permutation 을 시행하고, 224 개 p-value 전체에 BH 를 적용했다.

- q=0.05: 42/224 cells 생존
- q=0.10: 48/224 cells 생존
- 기존 locked cells: q=0.05 에서 4/4, q=0.10 에서 4/4 생존
- locked cell BH q-value: 모두 **0.000056**(Monte Carlo resolution 기준)

상세 결과는 [outputs/chum_multiplicity/BH_FDR_RESULTS.csv](#) 와

[MULTIPLICITY_REPORT.md](#) 에 공개했다.

GRU channel 결과 공개와 consensus 제외 사유

Locked cell	GRU conditional ΔAUROC	TCN LOO ΔAUROC	Transformer LOO ΔAUROC	GRU raw 방향	GRU consensus 사용
F4/XMV10	+0.4191	+0.1653	+0.1055	5/5 positive	제외
F19/XMV7	+0.0143	+0.1355	+0.1237	5/5 positive	제외
F19/XMV8	+0.0289	+0.0555	+0.0531	5/5 positive	제외
F25/XMV2	+0.0217	+0.2899	+0.2637	5/5 positive	제외

GRU raw 방향은 4/4 cell 에서 TCN·Transformer locked 방향과 같았다. 그러나

GRU 는 legacy conditional-mean 대치이고 TCN·Transformer 확정판은 LOO

residual sampling 이다. GRU 에는 동일한 paired hierarchical run CI 가 없고,

legacy imputer gate 에서 XMV8-XMV10 이 탈락했다. 따라서 이를 3-architecture

consensus 로 승격하지 않았다. 이는 GRU 불일치나 음성 결과 은폐가 아니라

조건 상이로 인한 비교 제외다. 전량 표는

outputs/architecture_consensus/THREE_ARCH_COMPARISON.csv 에 있다.

9.3 IG 교차검증

집합	셀 수	Spearman 중앙값	top-1 일치
Locked primary	8	0.5434	7/8, 87.5%
Negative/exploratory	8	0.1005	1/8, 12.5%

IG 와 CHUM 은 estimand 가 다르므로 동일값을 기대하지 않는다. 중요한 점은 모든 fault 에서 자동으로 일치한 것이 아니라 CHUM 효과가 강한 primary 집합에서만 높은 top-1 합의가 나타났다는 것이다.

불일치 1 건은 **TCN/F4** 다. IG 는 XMV6 을 top-1

(**normalized XMV IG=0.2608**)로, CHUM 은 XMV10 을 top-1 로 선택했다. IG 에서

XMV10 도 0.2481 로 근접한 2 위였지만, conditional replacement 의 ΔAUROC 는

XMV10 **+0.1653**, XMV6 **+0.0021** 로 크게 달랐다. 즉 경로 적분 기반 attribution 은

XMV6 에도 민감했지만 정상 조건부 대치 후 탐지 utility 는 XMV10 에 집중됐다.

상관-중복 입력에서 경로 기반 score attribution 과 조건부 탐지 utility 가 갈릴 수

있다는 사례이며, IG 를 보조 삼각검증으로만 사용한 이유다.

9.4 HAI 21.03 corrected v2

Variant	Parameters	AUROC	AUPRC	eTaF1	FPR	평균 지연
F0	26,909	0.8331	0.4743	0.5895	0.00267	47.48
F0-C	31,021	0.8301	0.4663	0.5807	0.00264	49.18
F1	30,941	0.8518	0.5049	0.6162	0.00270	43.74

•F1–F0: AUROC **+0.018745**, AUPRC **+0.030608**, eTaF1 **+0.026722**

•F1–F0-C: AUROC **+0.021744**, AUPRC **+0.038605**, eTaF1 **+0.035477**

•모든 전역 차이는 3/3 seed 에서 같은 방향

•직접 공격된 5 개 event-channel 셀의 normalized score loss: **+0.0588–+0.2146**, 모두 3/3 seed positive

3 개 model seed 에 대한 t 기반 95% CI 는 다음과 같다. 표본이 3 개뿐이므로

분포 가정에 민감한 기술적 불확실성 구간이며 독립 데이터셋 반복으로

해석하지 않는다.

F1-F0 metric	mean delta	95% t CI
AUROC	+0.018745	[+0.008222, +0.029269]
AUPRC	+0.030608	[+0.023288, +0.037927]
eTaF1	+0.026722	[-0.009483, +0.062926]

HAI 결과는 **제한적 외부 지지**다. AUROC/AUPRC 구간은 양수지만 eTaF1

구간은 0 을 포함하고, attack target 이 직접 control point 인 셀을 포함한다.

따라서 공격받지 않은 control context 의 보편적 유용성이나 TEP 와 동급의

확립된 증거로 해석하지 않는다.

9.5 후속 학습 길이·window 개발 실험 (2026-10-02 보충)

기존 핵심 결과와 구분하여 seed47 의 후속 개발 실험을 보고한다. 1A 에서는 정상 validation 으로 checkpoint 를 선택하며 학습 길이를 늘렸지만 F1 AUROC 가 개선되지 않았다. TCN 은 0.809665 에서 0.807946 로, Transformer 는 0.807394 에서 0.804357 로 변했다. 근거는 [outputs/chum_harness_20261001/TRAINING_BUDGET_REVIEW.json](#) 이며, 정상 예측 MSE 개선을 탐지력 개선으로 간주하지 않는다.

1B 는 두 구조 × F0/F1/F0-C × window 20/60/120 의 18/18 작업을 완료했다. 아래 F1 여섯 행은 [outputs/chum_window_extension_20261001/METRICS.csv](#) 에서 직접 생성했다. 동일한 기존 test 560 runs 를 개발 벤치마크로 사용하고 window 사이의 평가 시작 sample 을 121 로 맞췄다. 지연 단위는 sample 이며, 탐지된 run 의 평균 지연과 미탐에 1,401 sample 의 패널티를 부여한 평균을 구분한다. 후자는 생존분석의 검열 추정량이 아니다. AP 는 non-interpolated average precision 이며 분류 정확도가 아니다. 평가 구간의 이상 sample 비율은 약 74.52%이다.

구조	Window	AUROC	AP (저장 필드 auprc)	탐지 run 비율	탐지된 run 지연	미탐 패널티 포함 평균 지연	고장 이전 sample FPR
tcn	20	0.823312	0.942033	0.687500	32.584416	460.214286	0.009875
tcn	60	0.821922	0.941448	0.680357	23.467192	463.785714	0.010163
tcn	120	0.821554	0.941471	0.682143	27.204188	463.875000	0.010192
transformer	20	0.806122	0.935994	0.678571	24.084211	466.664286	0.009972
transformer	60	0.809442	0.937495	0.682143	27.560209	464.117857	0.010140
transformer	120	0.806637	0.936276	0.678571	24.442105	466.907143	0.009950

F1의 탐지 run 비율은 약 67.86–68.75%로 미탐 run도 약 31–32% 남았다. 고장 이전 sample FPR은 약 0.99–1.02%이다. 3 연속 경보의 고장 이전 run alarm 비율이 0이라는 결과는 sample FPR이 0이라는 뜻이 아니다. 정상 validation을 checkpoint 선택과 threshold 설정에 함께 사용했으며 별도 독립 calibration 자료를 둔 실험은 아니다.

긴 window가 일관된 이득을 주지는 않았다. 이 표만으로 최적 window나 새로운 방법의 성능 우위를 확정하지 않는다. 1B는 단일 model seed47이고 이미 관찰한 개발 run을 재사용했으므로 독립적인 일반화 검증이나 새로운 통계적 유의성의 근거가 아니다. Transformer F0와 F0-C는 동일 구조이므로 독립적인 두 구조의 지지로 세지 않는다. 1B의 TCN은 1A의 두 층에서 여섯 층으로 바뀌었고 공통 평가 구간도 조정되었으므로 1A와 1B의 직접 수치 차이를 window만의 인과적 효과로 해석할 수 없다. 이 보충 결과는 학습 조건의 한계를 공개하는 자료이며 기존 채널 감사 결과의 수치를 대체하지 않는다.

10. 대치 민감도 분석

10.1 전 셀에 동일 적용한 post-hoc 설계

- locked cells: **F4/XMV10**, **F19/XMV7**, **F19/XMV8**, **F25/XMV2**
- block length: **5**, **10**, **20**
- conditional draws: **1**, **3**, **10**
- architecture: TCN, Transformer
- seeds: **42–46**
- 기존 checkpoint 재사용, 재학습 없음
- paired hierarchical bootstrap 2,000 회

실행 task 390 개의 구성은 **360 perturbation + 30 original baseline** 이다.

360 은 4 cells × 2 architectures × 5 seeds × 9 settings 이고, original 은 두 F19 channel 이 같은 fault baseline 을 공유하므로 3 unique faults × 2 architectures × 5 seeds = 30 이다. [SENSITIVITY_CELL_RESULTS.csv](#) 의 360 행은 delta 가 정의되는 perturbation 만 담고, raw fault/run 표의 390 task 에는 공유 baseline 30 개가 포함된다. 추가 30 개는 negative control, 실패 재실행 또는 누락분이 아니다.

Git 이력에서는 config·판정 JSON·결과 CSV 가 같은 커밋에 처음 등장해 prospective preregistration 을 입증할 수 없다. 따라서 이 절의 기준은 post-hoc robustness rule 로 보고하며, 감사 근거는 [docs/PREREGISTRATION_AUDIT.md](#) 에 공개한다.

architecture–cell 하나가 robust 하려면 다음을 요구했다.

- positive mean Δ AUROC: 9/9 settings
- material Δ AUROC ≥ 0.02 : 최소 8/9
- positive seeds $\geq 4/5$: 최소 8/9
- hierarchical run CI 하한 > 0 : 최소 8/9
- absolute FPR shift ≤ 0.005 : 9/9
- 기준 설정 block 20/draws 3 이 모든 setting gate 통과

최종 PASS 는 네 셀 모두에서 두 architecture 가 robust 해야 한다.

10.2 결과

PASS — 4/4 locked cells 가 두 architecture 에서 통과했다. 실제로 8 개 architecture–cell 모두 positive/material/seed-stable/CI-positive/FPR guardrail 을 9/9 설정에서 만족했다.

Architecture · cell	9 개 설정 Δ AUROC 범위	최악 abs(Δ FPR)	결과
TCN · F4/XMV10	+0.16527–+0.16534	0.00075	PASS
Transformer · F4/XMV10	+0.10550–+0.10556	0.00075	PASS
TCN · F19/XMV7	+0.13541–+0.13579	0.00150	PASS
Transformer · F19/XMV7	+0.12356–+0.12388	0.00075	PASS

Architecture · cell	9 개 설정 Δ AUROC 범위	최악 abs(Δ FPR)	결과
TCN · F19/XMV8	+0.05543–+0.05554	0.00050	PASS
Transformer · F19/XMV8	+0.05304–+0.05310	0.00075	PASS
TCN · F25/XMV2	+0.28979–+0.29017	0.00125	PASS
Transformer · F25/XMV2	+0.26343–+0.26442	0.00150	PASS

최악 설정에서도 최소 Δ AUROC 는 **+0.05304** 로 material gate **+0.02** 의 2.65 배였다. 이 결과는 본 논문의 중심 결론이 block length 나 stochastic draw count 의 한 고정값에서만 생겼다는 가능성이 평가한 설정 범위에서는 관찰되지 않았음을 보여 준다.

11. 결과 해석과 한계

TEP 의 일곱 event-level gain fault 와 네 channel-level consensus cell 은 서로 다른 결과 단위다. 전자는 제어 입력 전체의 추가 이득이며, 후자는 특정 채널을 조건부로 대치한 뒤 나타나는 탐지력 감소다. event gain 이 있어도 imputer 품질 또는 구조 합의를 통과하지 못하면 채널 결론을 내리지 않는다. F26/XMV4 의 제외는 이 구분을 보여 준다.

224-cell BH 결과는 동일 TEP test run 분포에 대한 분석이다. run 별 두 구조와 다섯 seed 의 평균 효과를 사용한 단측 sign-flip 검정은 귀무가설 아래 run-cluster 부호 대칭을 가정한다. 공유 모델과 데이터가 만드는 의존성도 남는다. BH 보정을 모든 의존 구조에서의 오류율 보장으로 해석하거나, 5 개 모델 seed 를 5 개 독립 데이터셋으로 해석하지 않는다. seed-architecture-민감도 설정의 표결을 독립으로 곱한 결합 확률은 정식 유의확률로 사용하지 않는다.

민감도 결과는 선택된 네 셀에 대한 post-hoc 강건성 분석이다. Git 이력에서 규칙의 사전등록을 입증할 수 없으며, 9 개 설정의 반복 성공은 독립적인 9 개 연구가 아니다. 다른 대치 모델-운전 조건까지 강건성을 보장하지 않는다.

정상 데이터 기반 대치는 관찰적 분석이다. 다른 채널도 fault 의 영향을 받는 경우 대치값에 이상 정보가 잔존할 수 있고, 조건부 모델 오차가 효과에 영향을 줄 수 있다. 품질 gate 와 FPR 제한은 이를 점검하지만 교란의 제거를 증명하지 않는다. 선택된 채널을 물리적 고장 원인 또는 최적 제어 대상으로 해석하지 않는다.

HAI에서는 AUROC-AUPRC의 3-seed t 구간은 양수지만 eTaF1 구간은 0을 포함한다. 직접 공격된 제어 채널의 utility는 공격받지 않은 제어 이력의 일반적 가치와 구별해야 한다. TEP와 HAI의 수치도 서로 다른 사건 정의와 평가 조건에서 얻었으므로 효과크기를 단순 비교하지 않는다.

12. 재현성과 연구 무결성

2026-09-21 재검증은 원 증거 커밋 `bc6166f792e3faceb060a50de6219dddca393fd6`에서 필요한 표·manifest 25개를 임시 폴더에 읽어 기존 validator를 실행했다. 파일별 SHA-256과 validator 해시는 `outputs/closeout_validation/ARCHIVE_PROVENANCE.json`에 있다. 총 18개 검증이 통과했다. 무효화된 HAI v1에서는 무효화 상태만 확인하며 성능 수치를 사용하지 않았다.

별도로 200,000회 sign-flip 기반 BH 표를 재계산해 보존된 224행 전체와 비교했고 수치가 일치했다. 민감도 분석은 현재 보존된 fault/run 표에서 2,000회 bootstrap을 재실행했으며 4/4 consensus PASS가 일치했다. HAI 전역 지표의 t 구간도 원 seed 별 지표로 재계산했다.

이 절의 재현은 결과 표에서 분석을 다시 수행하는 재현이다. 모델 재학습, 원시 telemetry 전처리, 기존 G3 신뢰구간의 새 추정은 포함하지 않는다. HAI overlap 제거와 역할 분류는 보존 manifest를 점검한 것이다. 재실행 명령과 상세 범위는 `CHUM_CLOSEOUT_KO.md`를 따른다.

13. 결론

평가한 산업 시계열에서 제어 이력의 이득은 사건과 채널에 따라 달랐다. CHUM은 이 차이를 모델 용량, 정상 조건부 대치의 품질, 오경보 변화, 반복 실행 및 모델 구조 합의를 함께 고려해 측정했다. TEP에서는 네 fault-channel 셸이 두 구조와 민감도 설정에서 유지됐고, HAI에서는 제한적인 외부 지지를 얻었다. 이는 제어 이력의 예측 유용성에 대한 근거이며 인과 또는 root-cause 식별의 근거는 아니다. 향후 확장은 공격받지 않은 제어 이력과 새로운 운전 조건에서 같은 평가 절차가 유지되는지 검증하는 것이다.

참고문헌

- [1] Tonekaboni, S., Joshi, S., Campbell, K., Duvenaud, D. K., and Goldenberg, A. (2020). What went wrong and when? Instance-wise feature importance for time-series black-box models. NeurIPS 33. <https://proceedings.neurips.cc/paper/2020/hash/08fa43588c2571ade19bc0fa5936e028-Abstract.html>
- [2] Bento, J., Saleiro, P., Cruz, A. F., Figueiredo, M. A. T., and Bizarro, P. (2021). TimeSHAP: Explaining Recurrent Models through Sequence Perturbations. KDD. <https://arxiv.org/abs/2012.00073>

- [3] Hase, P., Xie, H., and Bansal, M. (2021). The Out-of-Distribution Problem in Explainability and Search Methods for Feature Importance Explanations. NeurIPS 34. <https://proceedings.neurips.cc/paper/2021/hash/1def1713ebf17722cbe300cfc1c88558-Abstract.html>
- [4] Sundararajan, M., Taly, A., and Yan, Q. (2017). Axiomatic Attribution for Deep Networks. ICML, PMLR 70:3319–3328. <https://proceedings.mlr.press/v70/sundararajan17a.html>
- [5] Reinartz, C., Kulahci, M., and Ravn, O. (2021). An extended Tennessee Eastman simulation dataset for fault-detection and decision support systems. Computers & Chemical Engineering, 149, 107281. <https://doi.org/10.1016/j.compchemeng.2021.107281>
- [6] AIRI Institute. FDDBenchmark, reinartz_tep distribution. <https://github.com/AIRI-Institute/fddbbenchmark/blob/main/README.md> (접근: 2026-09-21).
- [7] ICS Dataset. HIL-based Augmented ICS (HAI) Security Dataset, release 21.03. <https://github.com/icsdataset/hai> (접근: 2026-09-21).
- [8] eTaPR maintainers. eTaPR evaluation implementation. <https://github.com/wshw4ng/eTaPR> (접근: 2026-09-21; 기존 프로젝트의 saurf4ng/eTaPR 주소가 이 주소로 연결됨).

문헌 [1–4]의 서지 및 요약은 원 출판처 또는 저자 arXiv 초록으로 확인했다. TEP의 upstream 연구 [5]와 실제 사용한 FDDBenchmark 배포 계층 [6]을 구분한다. 본 연구의 2,800 runs-52개 변수는 로컬 배포본 감사 결과이며 upstream 전체 데이터의 모든 모드 변수를 사용했다는 뜻이 아니다. 배포본의 세부 변환 이력이 완전히 입증된 것은 아니다. HAI와 평가 구현의 출처는 [7, 8]이다. 기존 실행에 사용된 upstream commit까지 고정한 원시 데이터 재현은 이번 재검증 범위 밖이다.